《机器学习编程实践》课程——DAY 4

课程内容

- VAE 代码实现
- GAN 代码实现

-、 VAE 的实现

1 基本结构

VAE 由编码器 (Encoder) 和解码器 (Decoder) 组成:

- 编码器 $q_{\phi}(z|x)$: 将输入 x 映射到潜在空间 z,具体实现:

 - 隐藏层: 两层 MLP, ReLU 激活
 - 输出层: 并行输出 $\mu \in \mathbb{R}^d$ 和 $\log \sigma^2 \in \mathbb{R}^d$
- 潜在空间
- 解码器 $p_{\theta}(x|z)$: 从潜在变量 z 重构数据,具体实现:
 - 输入层: 采样 $z = \mu + \sigma \odot \epsilon$, $\epsilon \sim \mathcal{N}(0, I)$
 - 隐藏层: 两层 MLP, ReLU 激活
 - 输出层: Sigmoid 激活(针对像素值归一化)

2 重参数化技巧

通过噪声 $\epsilon \sim \mathcal{N}(0, I)$ 生成潜在变量:

$$z = \mu + \sigma \odot \epsilon \tag{1}$$

使得梯度可以通过随机节点反向传播。

- 3 代码实现
- 3.1 整体架构

```
class VanillaVAE(BaseVAE):
  def __init__(self,
      in_channels: int, # 输入图像的通道数
      latent_dim: int, #潜在空间的维度
      hidden_dims: List = None, # 编码器和解码器中各层的通道数列表
      **kwargs) -> None:
    super(VanillaVAE, self).__init__()
    self.latent_dim = latent_dim
    modules = []
    if hidden_dims is None:
      hidden_dims = [32, 64, 128, 256, 512] #
         如果没有提供潜在空间维度,则使用默认维度
    # 构建编码器的卷积层,每层包括卷积层、BatchNorm层、激活函数
    for h_dim in hidden_dims:
      modules.append(
        nn.Sequential(
           nn.Conv2d(in_channels, out_channels=h_dim,
               kernel_size= 3, stride= 2, padding = 1),
           nn.BatchNorm2d(h_dim),
           nn.LeakyReLU())
      )
      in_channels = h_dim
    self.encoder = nn.Sequential(*modules) # 将所有编码器层组合成一个序列
    # 定义两个全连接层,分别输出潜在分布的均值(mu)和方差的对数(log_var)
    self.fc_mu = nn.Linear(hidden_dims[-1]*4, latent_dim)
    self.fc_var = nn.Linear(hidden_dims[-1]*4, latent_dim)
    # 构建解码器
    modules = []
    # 解码器的输入层,将潜在变量映射回特征空间
    self.decoder_input = nn.Linear(latent_dim, hidden_dims[-1] * 4)
    # 反转 hidden_dims 的顺序, 用于解码器
```

```
hidden_dims.reverse()
  # 构建编码器的转置卷积层,每层包括转置卷积层、BatchNorm层、激活函数
  for i in range(len(hidden_dims) - 1):
    modules.append(
      nn.Sequential(
         nn.ConvTranspose2d(hidden_dims[i],
              hidden_dims[i + 1],
              kernel_size=3,
              stride = 2,
              padding=1,
              output_padding=1),
      nn.BatchNorm2d(hidden_dims[i + 1]),
       nn.LeakyReLU())
    )
  # 将所有解码器层组合成一个序列
  self.decoder = nn.Sequential(*modules)
  # 最终输出层,将特征映射回图像空间,并使用 Tanh 激活函数将输出限制在 [-1,
     1] 范围内
  self.final_layer = nn.Sequential(
           nn.ConvTranspose2d(hidden_dims[-1],
                     hidden_dims[-1],
                     kernel_size=3,
                     stride=2,
                     padding=1,
                     output_padding=1),
           nn.BatchNorm2d(hidden_dims[-1]),
           nn.LeakyReLU(),
           nn.Conv2d(hidden_dims[-1], out_channels= 3,
           kernel_size= 3, padding= 1),
           nn.Tanh())
# 将输入图像编码为潜在空间的均值和方差对数
def encode(self, input: Tensor) -> List[Tensor]:
  # 中间省略
  return [mu, log_var]
# 将潜在变量解码回图像空间
```

```
def decode(self, z: Tensor) -> Tensor:
  # 中间省略
  return result
# 实现重参数化技巧, 使得梯度可以通过随机采样过程反向传播
def reparameterize(self, mu: Tensor, logvar: Tensor) -> Tensor:
  #中间省略
  return eps * std + mu
# 完整的前向传播过程,返回解码结果、原始输入、均值和方差对数
def forward(self, input: Tensor, **kwargs) -> List[Tensor]:
  # 中间省略
  return [self.decode(z), input, mu, log_var]
# 计算VAE的损失函数
def loss_function(self, *args, **kwargs) -> dict:
  # 中间省略
  return {'loss': loss, 'Reconstruction_Loss':recons_loss.detach(),
     'KLD':-kld_loss.detach()}
# 从潜在空间采样并生成新图像
def sample(self, num_samples:int, current_device: int, **kwargs) ->
   Tensor:
  # 中间省略
  return samples
# 给定输入图像, 返回其重建结果
def generate(self, x: Tensor, **kwargs) -> Tensor:
  return self.forward(x)[0]
```

3.2 encode 方法

```
def encode(self, input: Tensor) -> List[Tensor]:
    result = self.encoder(input)
    result = torch.flatten(result, start_dim=1)

mu = self.fc_mu(result)
    log_var = self.fc_var(result)
```

```
return [mu, log_var]
```

3.3 decode 方法

```
def decode(self, z: Tensor) -> Tensor:
    result = self.decoder_input(z)
    result = result.view(-1, 512, 2, 2)
    result = self.decoder(result)
    result = self.final_layer(result)
    return result
```

3.4 重参数方法

```
def reparameterize(self, mu: Tensor, logvar: Tensor) -> Tensor:
    std = torch.exp(0.5 * logvar)
    eps = torch.randn_like(std)
    return eps * std + mu
```

3.5 forward 方法

```
def forward(self, input: Tensor, **kwargs) -> List[Tensor]:
    mu, log_var = self.encode(input)
    z = self.reparameterize(mu, log_var)
    return [self.decode(z), input, mu, log_var]
```

3.6 loss_function 方法

```
# 包括重建损失 (MSE)和KL散度损失 (衡量潜在分布与标准正态分布的差异)

def loss_function(self, *args, **kwargs) -> dict:
    recons = args[0]
    input = args[1]
    mu = args[2]
    log_var = args[3]

kld_weight = kwargs['M_N'] # Account for the minibatch samples from the dataset
    recons_loss =F.mse_loss(recons, input)
```

3.7 sample 方法

```
def sample(self, num_samples:int, current_device: int, **kwargs) ->
    Tensor:
    z = torch.randn(num_samples, self.latent_dim)
    z = z.to(current_device)
    samples = self.decode(z)
    return samples
```

3.8 generate 方法

```
def generate(self, x: Tensor, **kwargs) -> Tensor:
    return self.forward(x)[0]
```

二、 GAN 的实现

1 基本框架

GAN 由生成器 G 和判别器 D 组成:

- 生成器 G(z): 将噪声 z 映射到数据空间
- 判别器 D(x): 判断 x 来自真实数据还是生成器

2 目标函数

二者极小极大博弈:

$$\min_{G} \max_{D} V(D, G) = \mathbb{E}_{x \sim p_{data}}[\log D(x)] + \mathbb{E}_{z \sim p_z}[\log(1 - D(G(z)))]$$
 (2)

3 训练过程

- 固定 G, 更新 D 以最大化区分真实/生成样本
- 固定 D,更新 G 以最小化 $\log(1 D(G(z)))$

4 代码实现

4.1 生成器

```
class Generator(nn.Module):
  def __init__(self):
    super(Generator, self).__init__()
    self.label_emb = nn.Embedding(opt.n_classes, opt.n_classes)
    # 定义构建块函数,包含线性层、可选BatchNorm层和LeakyReLU激活
    def block(in_feat, out_feat, normalize=True):
       layers = [nn.Linear(in_feat, out_feat)]
       if normalize:
         layers.append(nn.BatchNorm1d(out_feat, 0.8))
         layers.append(nn.LeakyReLU(0.2, inplace=True))
       return layers
    # 生成器的主要结构
    self.model = nn.Sequential(
       # 输入: 噪声(100维) + 类别嵌入(10维) = 110维
       #4个全连接块,维度逐渐增加
       *block(opt.latent_dim + opt.n_classes, 128, normalize=False),
       *block(128, 256),
       *block(256, 512),
       *block(512, 1024),
       # 使用Tanh激活将输出压缩到[-1,1]范围
      nn.Linear(1024, int(np.prod(img_shape))),
       nn.Tanh()
    )
  # 前向传播
  def forward(self, noise, labels):
    gen_input = torch.cat((self.label_emb(labels), noise), -1) #
        将标签嵌入和噪声拼接
    img = self.model(gen_input) # 通过模型生成图像
```

```
img = img.view(img.size(0), *img_shape) # 调整形状为(批量大小, 通道, 高, 宽)
return img
```

4.2 判别器

```
class Discriminator(nn.Module):
  def init (self):
    super(Discriminator, self).__init__()
    self.label_embedding = nn.Embedding(opt.n_classes, opt.n_classes)
    # 判别器的主要结构
    self.model = nn.Sequential(
       # 输入: 展平的图像(32x32=1024) + 类别嵌入(10) = 1034维
       #3个全连接层,使用Dropout防止过拟合
       nn.Linear(opt.n_classes + int(np.prod(img_shape)), 512),
       nn.LeakyReLU(0.2, inplace=True),
       nn.Linear(512, 512),
       nn.Dropout(0.4),
       nn.LeakyReLU(0.2, inplace=True),
       nn.Linear(512, 512),
       nn.Dropout(0.4),
       nn.LeakyReLU(0.2, inplace=True),
       nn.Linear(512, 1),
    )
  # 前向传播
  def forward(self, img, labels):
    # 拼接图像和标签嵌入
    d_in = torch.cat((img.view(img.size(0), -1),
        self.label_embedding(labels)), -1)
    # 通过模型输出真假判断
    validity = self.model(d_in)
    return validity
```

4.3 训练过程

```
for epoch in range(opt.n_epochs): # 循环遍历训练周期
```

```
for i, (imgs, labels) in enumerate(dataloader): # 循环遍历数据批次
batch_size = imgs.shape[0]
# 定义真实和假标签
valid = Variable(FloatTensor(batch_size, 1).fill_(1.0),
   requires_grad=False)
fake = Variable(FloatTensor(batch_size, 1).fill_(0.0),
   requires_grad=False)
real_imgs = Variable(imgs.type(FloatTensor))
labels = Variable(labels.type(LongTensor))
# 训练生成器
optimizer_G.zero_grad() # 清空梯度
# 生成随机噪声和随机标签
z = Variable(FloatTensor(np.random.normal(0, 1, (batch_size,
   opt.latent_dim))))
gen_labels = Variable(LongTensor(np.random.randint(0, opt.n_classes,
   batch_size)))
# 生成图像
gen_imgs = generator(z, gen_labels)
# Loss measures generator's ability to fool the discriminator
validity = discriminator(gen_imgs, gen_labels)
g_loss = adversarial_loss(validity, valid)
g_loss.backward()
optimizer_G.step()
# 训练判别器
optimizer_D.zero_grad()
# 计算真实图像损失
validity_real = discriminator(real_imgs, labels)
d_real_loss = adversarial_loss(validity_real, valid)
# 计算生成图像损失
```